

Twelve Tips for Reproducible Analysis of Single-Cell Transcriptomics Data

Journal Club InforBio

Lijiao NING

2026-06-08

Pourquoi cet article ?

Constat

doi: [10.1145/3736731.3746138](https://doi.org/10.1145/3736731.3746138)

- Les analyses scRNA-seq sont complexes et très paramétrables
- Les résultats (UMAP, clustering, DE) dépendent souvent :
 - des paramètres
 - des versions logicielles
 - de l'environnement de calcul
- Les notebooks seuls ne garantissent pas la reproductibilité
- Beaucoup d'articles ne fournissent pas suffisamment de code ou de documentation

Objectif de l'article

Proposer une **architecture complète** permettant de réaliser des analyses scRNA-seq reproductibles.

Répétabilité vs. reproductibilité

Répétabilité

- Même données/méthodes/ordinateur

→ mêmes résultats

Reproductibilité

- Même données/méthodes
- Mais **ordinateur différent**

→ mêmes résultats

! Message central

- Un notebook seul favorise la répétabilité.
- Pour obtenir la reproductibilité il faut aussi contrôler l'environnement logiciel.

Les 12 tips

Les auteurs regroupent les recommandations en 4 thèmes :

1. Organisation du workflow

- notebooks
- arborescence des fichiers

2. Analyse des données

- metadata
- traitement individuel
- intégration
- analyses biologiques
- figures

3. Reproductibilité informatique

- fonctions
- conteneur
- vérification

4. Accessibilité

- portail web
- partage

Tip 1 : notebook structuré




Figure 2, Onfroy et al. (2025)

Utiliser des notebooks structurés

Les auteurs recommandent :

- même structure dans tous les notebooks
- paramètres globaux au début
- chargement des données séparé du traitement
- chemins relatifs
- commentaires en langage naturel
- `sessionInfo()` à la fin

⚠ Important

Rendre fréquemment les notebooks pour vérifier qu'ils s'exécutent du début à la fin.

Tip 2 : arborescence du projet




Figure 3, Onfroy et al. (2025)

Organiser le projet

Chaque étape possède son propre notebook.

Structure proposée :

1. metadata
2. individual datasets
3. combined datasets
4. biological analyses
5. final figures



Intérêt

- navigation facile
- moins de copier-coller
- reprise facile de l'analyse
- traçabilité des résultats

Tip 3 : centraliser les metadata

Pourquoi ?

Éviter :

- incohérences
- copier-coller
- erreurs entre notebooks

Exemples :

- description des échantillons
- couleurs
- marqueurs cellulaires
- annotations

Définir les metadata une seule fois




Figure 4, Onfroy et al. (2025)

Workflow d'analyse proposé

1. Traitement individuel

- QC
- filtrage
- normalisation
- annotation

2. Intégration

- fusion des jeux de données
- correction batch éventuelle

3. Analyse biologique

- DE
- enrichissement
- analyses spécifiques

4. Figures finales

Notebook dédié

Les tips 8-10 : rendre l'analyse reproductible

Fonctions personnalisées

- centralisées dans un package

Conteneur logiciel

Apptainer ou Docker, qui contient :

- OS
- R
- packages
- dépendances

Vérification

Rejouer les notebooks dans le conteneur :

- même nombre de cellules
- mêmes annotations
- mêmes résultats biologiques

Fixer les random seeds.

Les tips 11–12 : partager l'analyse

Objectif

Permettre à un tiers de comprendre et reproduire l'analyse.

Les auteurs proposent de créer une vue globale du projet, avec :

- génération automatique d'un portail HTML
- navigation entre notebooks
- GitHub Pages

Partage de :

- codes
- environnement logiciel
- données

Utilisation de Zenodo

[Zenodo](#) est un dépôt scientifique géré par le CERN (Centre Européen de Recherche Nucleaire).

- Exemple : Développement sur GitHub → Release v1.0 → Connexion GitHub-Zenodo → Archive automatique → DOI

Les auteurs ont déposé sur Zenodo :

- les matrices de comptage ;
- les notebooks ;
- leur package `aquarius` ;
- le conteneur `Apptainer` ;
- le repertoire GitHub de l'outil d'organisation des HTML.

- GitHub sert au développement et au partage du code
- Zenodo sert à archiver une version figée et citable (DOI) garantissant la reproductibilité à long terme.

Messages à retenir

- La reproductibilité est considérée comme une composante du workflow dès le début du projet.
- Les notebooks aident, mais ne suffisent pas sans gestion des fichiers et de l'environnement.

 message final

Moins de chaos, plus de traçabilité, et plus de confiance dans les résultats.